

**PREDIKSI TINGKAT PENGANGGURAN TERBUKA (TPT) DI
INDONESIA BERDASARKAN PROVINSI MENGGUNAKAN MODEL
LONG SHORT-TERM MEMORY (LSTM)**

Oleh:

**ERIATI ERLINDA
NIM. 221113394
RACHEL ADINDA Br. SILABAN
NIM. 221112623
DEVI PUTRIANI SINAGA
NIM. 221112186**



**PROGRAM STUDI S-1 TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS MIKROSKIL
MEDAN
2026**

DAFTAR ISI

DAFTAR ISI	ii
DAFTAR GAMBAR	iii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Tujuan	2
1.4 Manfaat	2
BAB II TINJAUAN PUSTAKA	4
2.1 Tingkat Pengangguran Terbuka (TPT)	4
2.2 Data Time Series dalam Analisis Ketenagakerjaan	4
2.3 Deep Learning dalam Peramalan Data Ekonomi.....	5
2.4 Long Short-Term Memory (LSTM)	6
2.5 Penelitian Terkait	6
BAB III TAHAPAN PELAKSANAAN	7
3.1 Sumber Data	7
3.2 Tahapan Penelitian.....	7
3.3 Praproses Data.....	8
3.4 Arsitektur Model LSTM.....	8
3.5 Fitur Unik Proyek Deep Learning	9
3.6 Teknologi dan Deployment.....	10
BAB IV HASIL DAN PEMBAHASAN	12
4.1 Analisis Deskriptif Data Tingkat Pengangguran Terbuka (TPT)	12
4.2 Hasil Pelatihan Model LSTM.....	13
4.3 Visualisasi Hasil Prediksi.....	14
4.4 Pembahasan Hasil Penelitian	14
BAB V PENUTUP	16
5.1 Kesimpulan	16
5.2 Saran.....	16
DAFTAR PUSTAKA	18

DAFTAR GAMBAR

Gambar 3. 1 Tampilan Fitur Unik.....	10
Gambar 4. 1 Data TPT Setelah Praproses	12
Gambar 4. 2 Ringkasan Hasil Pelatihan Model LSTM	13
Gambar 4. 3 Grafik Perbandingan Data Aktual dan Hasil Prediksi Tingkat Pengangguran Terbuka (TPT) Menggunakan Model LSTM	14

BAB I

PENDAHULUAN

1.1 Latar Belakang

Tingkat Pengangguran Terbuka (TPT) merupakan salah satu indikator utama yang digunakan untuk menggambarkan kondisi ketenagakerjaan dan stabilitas ekonomi suatu wilayah. Tingginya angka TPT menunjukkan adanya ketidakseimbangan antara jumlah angkatan kerja dan kesempatan kerja yang tersedia [1]. Di Indonesia, TPT masih menjadi permasalahan penting karena nilainya berbeda-beda antar provinsi dan mengalami fluktuasi dari waktu ke waktu akibat pengaruh pertumbuhan ekonomi, kebijakan pemerintah, serta kondisi global.

Perbedaan karakteristik ekonomi, tingkat pendidikan, struktur industri, dan jumlah penduduk antar provinsi menyebabkan variasi TPT yang signifikan. Beberapa provinsi cenderung memiliki tingkat pengangguran yang tinggi dan sulit ditekan, sementara provinsi lain relatif stabil. Kondisi ini menimbulkan tantangan bagi pemerintah dalam merumuskan kebijakan ketenagakerjaan yang tepat sasaran karena diperlukan pemahaman yang akurat mengenai pola dan tren TPT di setiap wilayah [2].

Selama ini, analisis TPT umumnya dilakukan secara deskriptif atau menggunakan metode statistik konvensional yang memiliki keterbatasan dalam menangkap pola nonlinier dan ketergantungan jangka panjang pada data runtut waktu. Padahal, data TPT bersifat time series dan dipengaruhi oleh nilai-nilai historis sebelumnya. Keterbatasan metode konvensional tersebut dapat menyebabkan hasil prediksi yang kurang optimal dan kurang responsif terhadap perubahan pola data.

Seiring dengan perkembangan teknologi, metode deep learning khususnya Long Short-Term Memory (LSTM) menjadi solusi yang potensial dalam memprediksi data time series. Model LSTM dirancang untuk mampu mengingat informasi jangka panjang dan menangkap pola kompleks pada data historis. Dengan kemampuan tersebut, LSTM dinilai lebih akurat dalam memodelkan dan memprediksi TPT berdasarkan data historis di masing-masing provinsi di Indonesia [3].

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk membangun model prediksi Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi menggunakan metode Long Short-Term Memory (LSTM). Hasil prediksi yang diperoleh diharapkan dapat memberikan gambaran tren TPT di masa mendatang serta menjadi bahan

pertimbangan bagi pemerintah dan pemangku kepentingan dalam merumuskan kebijakan ketenagakerjaan yang lebih efektif dan berbasis data.

1.2 Rumusan Masalah

Rumusan masalah dalam penelitian ini dinyatakan dalam bentuk pernyataan sebagai berikut:

1. Penelitian ini menganalisis pola dan karakteristik Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi menggunakan data historis.
2. Penelitian ini membahas proses praproses data Tingkat Pengangguran Terbuka (TPT) agar sesuai digunakan dalam pemodelan data time series dengan metode Long Short-Term Memory (LSTM).
3. Penelitian ini mengevaluasi kinerja model Long Short-Term Memory (LSTM) dalam memprediksi Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi.

1.3 Tujuan

Tujuan penelitian ini adalah sebagai berikut:

1. Untuk menganalisis pola dan karakteristik Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi menggunakan data historis.
2. Untuk menerapkan metode Long Short-Term Memory (LSTM) dalam membangun model prediksi Tingkat Pengangguran Terbuka (TPT) berbasis data time series.
3. Untuk menghasilkan prediksi Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi yang dapat digunakan sebagai bahan pertimbangan dalam perencanaan dan pengambilan kebijakan ketenagakerjaan.

1.4 Manfaat

Manfaat yang diharapkan dari penelitian ini adalah sebagai berikut:

1. Memberikan manfaat akademik berupa penambahan referensi dan wawasan keilmuan mengenai penerapan metode Long Short-Term Memory (LSTM) dalam memprediksi indikator ketenagakerjaan, khususnya Tingkat Pengangguran Terbuka (TPT) berbasis data time series.
2. Memberikan manfaat praktis berupa informasi dan gambaran prediksi Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi yang dapat

digunakan sebagai bahan pertimbangan dalam perencanaan dan pengambilan kebijakan ketenagakerjaan.

3. Memberikan manfaat metodologis sebagai acuan bagi peneliti selanjutnya dalam mengembangkan atau membandingkan metode prediksi lain pada data ekonomi dan ketenagakerjaan.

BAB II

TINJAUAN PUSTAKA

2.1 Tingkat Pengangguran Terbuka (TPT)

Tingkat Pengangguran Terbuka (TPT) merupakan salah satu indikator utama dalam ketenagakerjaan yang digunakan untuk mengukur persentase penduduk usia kerja yang tidak bekerja tetapi sedang aktif mencari pekerjaan atau sedang mempersiapkan usaha. Indikator ini mencerminkan kemampuan suatu perekonomian dalam menyerap tenaga kerja yang tersedia serta menunjukkan tingkat efektivitas pasar kerja di suatu wilayah.

Di Indonesia, pengukuran TPT dilakukan oleh Badan Pusat Statistik (BPS) melalui Survei Angkatan Kerja Nasional (SAKERNAS). Data TPT disajikan secara berkala dan mencakup berbagai tingkatan wilayah, mulai dari nasional hingga provinsi. Penyajian data berdasarkan provinsi memungkinkan dilakukan analisis perbandingan kondisi ketenagakerjaan antar daerah yang memiliki karakteristik ekonomi, sosial, dan demografis yang berbeda-beda.

Perbedaan nilai TPT antar provinsi dipengaruhi oleh berbagai faktor, seperti struktur perekonomian daerah, tingkat industrialisasi, kualitas sumber daya manusia, serta ketersediaan lapangan pekerjaan. Provinsi dengan dominasi sektor informal atau sektor primer cenderung memiliki karakteristik TPT yang berbeda dibandingkan provinsi dengan sektor industri dan jasa yang lebih berkembang.

Tingginya tingkat pengangguran terbuka dapat menimbulkan berbagai dampak negatif, antara lain meningkatnya angka kemiskinan, menurunnya daya beli masyarakat, serta meningkatnya permasalahan sosial. Oleh karena itu, TPT tidak hanya digunakan sebagai indikator statistik, tetapi juga sebagai dasar perumusan kebijakan ketenagakerjaan dan pembangunan ekonomi baik di tingkat pusat maupun daerah.

Selain analisis kondisi saat ini, informasi TPT juga perlu dikaji secara prediktif. Prediksi TPT menjadi penting agar pemerintah dapat mengantisipasi potensi peningkatan pengangguran di masa mendatang dan menyusun kebijakan yang lebih proaktif serta tepat sasaran.

2.2 Data Time Series dalam Analisis Ketenagakerjaan

Data time series merupakan data yang dikumpulkan dan dicatat secara berurutan berdasarkan interval waktu tertentu, seperti tahunan, triwulanan, atau bulanan. Data Tingkat

Pengangguran Terbuka (TPT) termasuk dalam kategori data time series karena nilainya diamati secara periodik dan saling berkaitan antar waktu pengamatan. Analisis data time series bertujuan untuk memahami perilaku data dari waktu ke waktu, termasuk mengidentifikasi tren jangka panjang, pola musiman, dan fluktuasi yang terjadi. Dalam konteks ketenagakerjaan, analisis time series memungkinkan peneliti untuk mempelajari dinamika pasar tenaga kerja serta perubahan kondisi ekonomi yang memengaruhi tingkat pengangguran.

Data TPT sering kali dipengaruhi oleh faktor eksternal seperti pertumbuhan ekonomi, kebijakan pemerintah, krisis ekonomi, dan kondisi global. Faktor-faktor tersebut menyebabkan data TPT memiliki pola yang kompleks, tidak linier, dan sulit diprediksi menggunakan pendekatan sederhana. Metode statistik konvensional dalam analisis time series memiliki keterbatasan dalam menangkap pola nonlinier dan ketergantungan jangka panjang pada data. Oleh karena itu, diperlukan metode analisis yang lebih fleksibel dan adaptif agar dapat memodelkan karakteristik data TPT secara lebih akurat.

Dengan memanfaatkan pendekatan time series yang tepat, prediksi TPT diharapkan mampu memberikan gambaran kondisi ketenagakerjaan di masa depan yang lebih realistis dan dapat digunakan sebagai dasar perencanaan kebijakan.

2.3 Deep Learning dalam Peramalan Data Ekonomi

Deep learning merupakan cabang dari machine learning yang menggunakan jaringan saraf tiruan dengan banyak lapisan untuk mempelajari pola kompleks dalam data. Pendekatan ini mampu mengolah data dalam jumlah besar serta mengenali hubungan nonlinier yang sulit ditangkap oleh metode analisis tradisional. Dalam bidang ekonomi, deep learning telah banyak diterapkan untuk peramalan berbagai indikator makroekonomi seperti inflasi, pertumbuhan ekonomi, nilai tukar, dan tingkat pengangguran. Keunggulan utama deep learning terletak pada kemampuannya dalam mempelajari pola historis secara otomatis tanpa memerlukan banyak asumsi matematis.

Model deep learning sangat sesuai digunakan pada data time series ekonomi yang memiliki fluktuasi tinggi dan pola yang dinamis. Dengan arsitektur jaringan yang tepat, model ini mampu menangkap hubungan jangka pendek maupun jangka panjang pada data historis. Penerapan deep learning dalam peramalan ekonomi memberikan hasil yang lebih adaptif terhadap perubahan pola data. Hal ini menjadikan deep learning sebagai alternatif yang menjanjikan dibandingkan metode statistik konvensional dalam memprediksi indikator ekonomi yang kompleks seperti TPT.

2.4 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) merupakan salah satu arsitektur dari Recurrent Neural Network (RNN) yang dirancang untuk mengatasi permasalahan long-term dependency pada data time series. LSTM memiliki mekanisme khusus yang memungkinkan jaringan menyimpan informasi penting dalam jangka waktu yang panjang. Struktur LSTM terdiri dari cell state dan tiga gerbang utama, yaitu forget gate, input gate, dan output gate. Ketiga gerbang tersebut berfungsi untuk mengatur aliran informasi, menentukan informasi yang perlu dipertahankan, dan informasi yang perlu dilupakan oleh model.

Kemampuan LSTM dalam mengingat pola historis menjadikannya sangat efektif dalam memodelkan data runtut waktu yang kompleks. Model ini mampu menangkap tren jangka panjang serta fluktuasi data dengan lebih baik dibandingkan RNN konvensional. Dalam penelitian ini, LSTM digunakan untuk memprediksi Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi. Penggunaan LSTM diharapkan mampu menghasilkan prediksi yang lebih akurat dan stabil karena model dapat mempelajari pola historis TPT secara mendalam.

2.5 Penelitian Terkait

Berbagai penelitian terdahulu menunjukkan bahwa model LSTM memiliki kinerja yang baik dalam memprediksi data time series di bidang ekonomi dan ketenagakerjaan. LSTM terbukti mampu menangkap pola tren dan fluktuasi pada data pengangguran secara lebih efektif. Hasil penelitian sebelumnya juga menunjukkan bahwa LSTM sering menghasilkan tingkat kesalahan prediksi yang lebih rendah dibandingkan metode statistik konvensional seperti ARIMA. Hal ini menunjukkan bahwa LSTM memiliki potensi besar untuk digunakan dalam peramalan indikator ketenagakerjaan.

Berdasarkan hasil penelitian terdahulu tersebut, penggunaan metode LSTM dalam penelitian ini dinilai relevan dan tepat. Penelitian ini diharapkan dapat memperkuat temuan sebelumnya serta memberikan kontribusi baru dalam penerapan deep learning untuk prediksi Tingkat Pengangguran Terbuka (TPT) di Indonesia [4].

BAB III

TAHAPAN PELAKSANAAN

3.1 Sumber Data

Data yang digunakan dalam penelitian ini merupakan data Tingkat Pengangguran Terbuka (TPT) Indonesia berdasarkan provinsi yang bersumber dari Badan Pusat Statistik (BPS). Dataset mencakup 38 provinsi dengan rentang data tahunan dari berbagai tahun.

Link Dataset: <https://www.bps.go.id/id/query-builder>

3.2 Tahapan Penelitian

Tahapan penelitian dilakukan secara sistematis untuk memastikan data yang digunakan valid dan model LSTM dapat bekerja secara optimal. Tahapan yang dilakukan meliputi:

1. Pengumpulan Data TPT Berdasarkan Provinsi

Data Tingkat Pengangguran Terbuka (TPT) dikumpulkan dari sumber resmi, yaitu Badan Pusat Statistik (BPS). Data yang digunakan mencakup seluruh provinsi di Indonesia dan rentang waktu tahunan tertentu. Tahap ini memastikan bahwa data historis yang digunakan representatif dan lengkap untuk analisis.

2. Pembersihan dan Praproses Data

Data yang diperoleh perlu dibersihkan dari kesalahan, duplikasi, dan nilai yang tidak valid. Tahap ini termasuk menangani missing value, transformasi format data, serta normalisasi agar nilai TPT berada dalam rentang yang sesuai untuk proses pelatihan model LSTM.

3. Pembentukan Data Time Series

Data diubah menjadi format time series agar model LSTM dapat mengenali pola temporal. Setiap provinsi dibuat sebagai seri waktu tersendiri, sehingga model dapat mempelajari tren jangka panjang dan fluktuasi TPT di masing-masing wilayah.

4. Pembangunan dan Pelatihan Model LSTM

Model LSTM dibangun dengan arsitektur yang sesuai untuk data time series. Proses pelatihan dilakukan untuk mempelajari pola historis TPT sehingga model dapat menghasilkan prediksi yang mendekati data aktual.

5. Evaluasi Hasil Prediksi

Setelah model dilatih, kinerjanya dievaluasi dengan membandingkan nilai prediksi terhadap data aktual. Evaluasi dilakukan untuk menilai akurasi model dan mengetahui sejauh mana model dapat menangkap tren serta pola TPT.

3.3 Praproses Data

Praproses data merupakan tahap penting agar data siap digunakan dalam pemodelan LSTM. Tahap ini meliputi:

1. Menghapus Baris dan Kolom Tidak Relevan

Baris atau kolom yang tidak berkontribusi pada analisis TPT dihilangkan, agar model fokus pada variabel yang relevan.

2. Mengonversi Data ke Format Numerik

Semua nilai diubah menjadi format numerik agar dapat diproses oleh algoritma LSTM.

3. Menangani Nilai Kosong atau Tanda '-'

Nilai kosong atau simbol yang tidak sesuai diganti dengan metode imputasi atau dihapus, agar tidak mengganggu proses pelatihan model.

4. Normalisasi Data

Data diubah menjadi skala tertentu (misal 0–1) agar model LSTM dapat mempelajari pola dengan lebih efisien dan stabil. Normalisasi membantu mempercepat konvergensi model saat pelatihan

3.4 Arsitektur Model LSTM

Model LSTM dibangun menggunakan beberapa layer utama, yaitu layer LSTM yang berfungsi untuk menangkap pola temporal dan ketergantungan jangka panjang pada data time series, serta layer Dense sebagai lapisan output untuk menghasilkan nilai prediksi Tingkat Pengangguran Terbuka (TPT). Arsitektur model disesuaikan dengan karakteristik data agar mampu mempelajari pola historis TPT secara optimal.

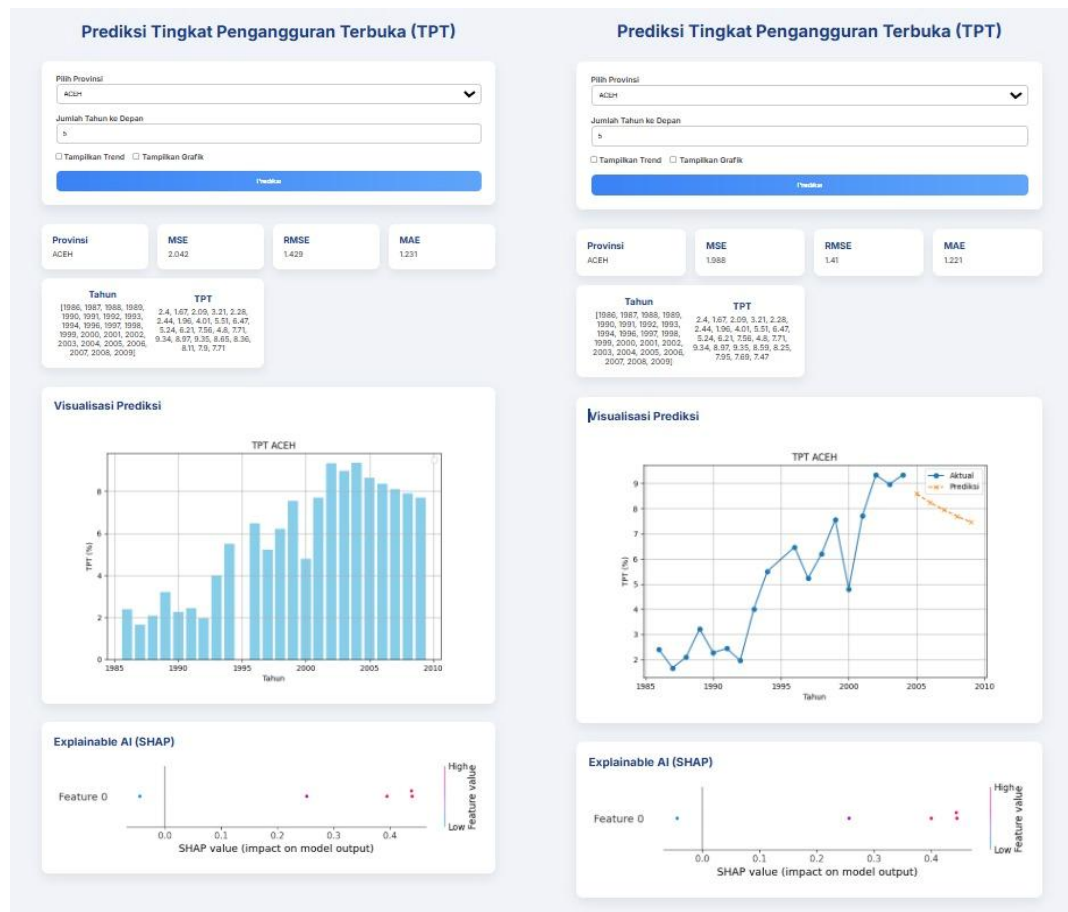
Dalam proses implementasi model, pemilihan provinsi yang dianalisis belum dilakukan secara interaktif melalui antarmuka pengguna. Pemilihan provinsi ditentukan secara manual melalui kode program dengan menetapkan nama provinsi pada variabel tertentu. Hal ini disebabkan karena model diimplementasikan dan dijalankan pada lingkungan Google Colab yang lebih berfokus pada proses komputasi, pelatihan model, dan analisis data dibandingkan pengembangan antarmuka interaktif.

Oleh karena itu, untuk menampilkan hasil prediksi dan visualisasi dari provinsi tertentu, pengguna perlu mengubah nama provinsi secara langsung di dalam variabel kode program. Pendekatan ini dinilai memadai untuk tujuan penelitian dan evaluasi model karena tidak memengaruhi kinerja maupun hasil prediksi LSTM. Mekanisme tersebut hanya berfungsi sebagai cara pemilihan data yang dianalisis, sementara proses pemodelan dan perhitungan prediksi tetap berjalan secara konsisten.

3.5 Fitur Unik Proyek Deep Learning

Fitur unik pertama adalah multi-step forecasting menggunakan LSTM untuk memprediksi Tingkat Pengangguran Terbuka (TPT) beberapa tahun ke depan sekaligus. Misalnya, jika data tersedia hingga 2023, model dapat memprediksi TPT dari 2024–2028. Pendekatan ini menangkap pola temporal jangka panjang dan dinamika perubahan TPT, serta dievaluasi menggunakan RMSE untuk memastikan akurasi prediksi. Fitur unik kedua adalah penggunaan Explainable AI dengan SHAP. SHAP menjelaskan pengaruh data historis terhadap prediksi TPT, sehingga stakeholder dapat memahami alasan model membuat prediksi tertentu. Pendekatan ini inovatif karena jarang diterapkan dalam proyek time series multi-step forecasting.

Selain itu, hasil prediksi divisualisasikan dalam grafik tren dan perbandingan antar periode, memudahkan pengguna memahami pola perubahan TPT dan membandingkan data aktual dengan prediksi model. Dengan kombinasi multi-step LSTM, SHAP, dan visualisasi, proyek ini menyajikan prediksi yang akurat sekaligus memberikan insight yang jelas dan aplikatif.



Gambar 3. 1 Tampilan Fitur Unik

3.6 Teknologi dan Deployment

Pengembangan dan implementasi model Long Short-Term Memory (LSTM) dalam penelitian ini dilakukan menggunakan bahasa pemrograman Python. Beberapa pustaka utama yang digunakan meliputi NumPy dan Pandas untuk pengolahan dan manipulasi data, Matplotlib untuk visualisasi hasil, serta TensorFlow dan Keras untuk pembangunan, pelatihan, dan evaluasi model Deep Learning. Selain itu, SHAP digunakan untuk analisis explainable AI, sehingga faktor-faktor yang memengaruhi prediksi model dapat dipahami secara transparan. Seluruh pustaka tersebut digunakan untuk mendukung proses pemodelan data time series Tingkat Pengangguran Terbuka (TPT) secara efektif dan terstruktur.

Untuk deployment, Flask digunakan sebagai framework untuk membangun aplikasi web sederhana yang menampilkan hasil prediksi TPT dan visualisasi model. Seluruh tahapan pengolahan data, pelatihan model, evaluasi kinerja, serta deployment dijalankan pada lingkungan pengembangan Visual Studio Code (VS Code). VS Code dipilih karena menyediakan dukungan yang baik untuk pengembangan aplikasi Python, kemudahan pengelolaan kode, serta integrasi fleksibel dengan pustaka Deep Learning. Lingkungan ini

memungkinkan proses eksperimen dan deployment dilakukan secara terorganisasi serta mudah direplikasi.

Deployment model dilakukan dalam bentuk program Python yang dapat dijalankan secara langsung melalui VS Code. Pengguna dapat melakukan pelatihan ulang model, menentukan provinsi yang dianalisis melalui pengaturan variabel dalam kode program, serta menampilkan hasil prediksi dan visualisasi Tingkat Pengangguran Terbuka (TPT). Pendekatan deployment ini dinilai memadai untuk tujuan penelitian dan evaluasi akademik karena memungkinkan replikasi eksperimen, pengujian ulang model, serta pemanfaatan hasil prediksi tanpa memerlukan pengembangan sistem atau infrastruktur tambahan.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Analisis Deskriptif Data Tingkat Pengangguran Terbuka (TPT)

Analisis deskriptif dilakukan untuk memahami karakteristik data Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi sebelum dilakukan proses pemodelan dan prediksi. Data yang digunakan merupakan data historis TPT per provinsi dengan rentang tahun yang berbeda-beda, mulai dari tahun 1986 hingga 2025. Berdasarkan hasil eksplorasi awal, dataset masih memiliki beberapa permasalahan, antara lain kolom tahun yang tersebar dalam bentuk wide format, adanya kolom tidak relevan seperti Unnamed, serta nilai kosong pada beberapa tahun. Oleh karena itu, dilakukan proses pembersihan dan transformasi data agar sesuai untuk pemodelan time series.

Hasil pembersihan data menunjukkan bahwa kolom yang tidak relevan berhasil dihapus dan struktur data diubah menjadi format long dengan tiga atribut utama, yaitu provinsi, tahun, dan nilai TPT. Gambar hasil transformasi data dapat dilihat pada gambar berikut



	provinsi	tahun	tpt
1	ACEH	2001	7.71
2	SUMATERA UTARA	2001	9.09
3	SUMATERA BARAT	2001	8.74
4	RIAU	2001	6.43
5	JAMBI	2001	5.61

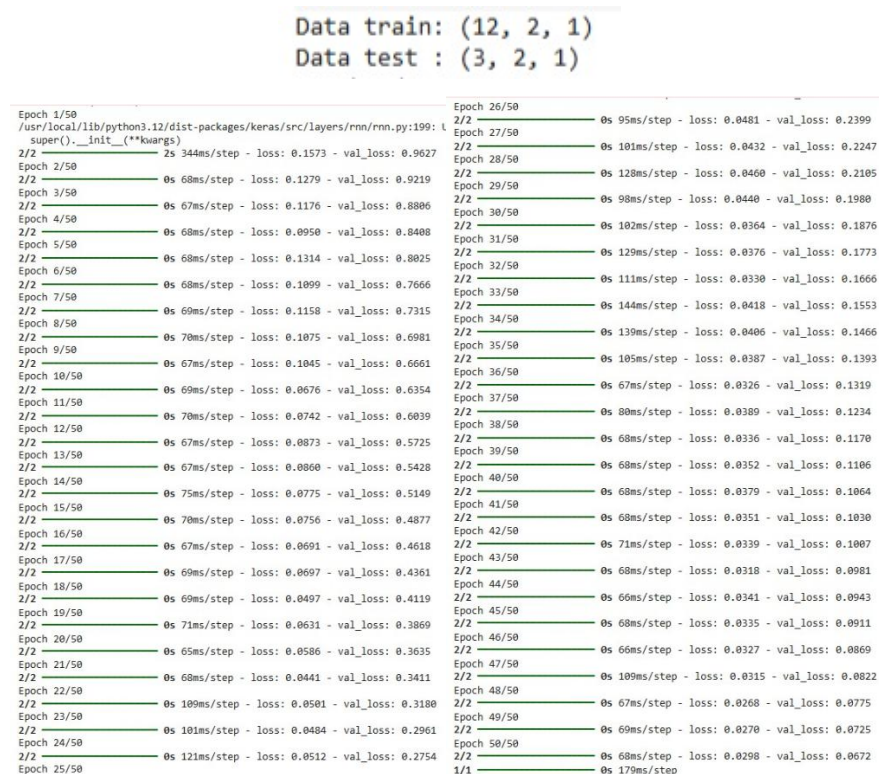
Gambar 4. 1 Data TPT Setelah Praproses

Selain itu, data historis menunjukkan adanya variasi nilai TPT antar provinsi. Sebagai contoh, Provinsi Jawa Barat memiliki data TPT yang relatif fluktuatif dari tahun ke tahun, sedangkan beberapa provinsi lain menunjukkan pola yang lebih stabil. Perbedaan ini mencerminkan kondisi ekonomi, struktur industri, serta tingkat penyerapan tenaga kerja yang berbeda di setiap wilayah. Dari sisi temporal, data TPT juga mengalami fluktuasi dari waktu ke waktu. Fluktuasi tersebut dapat dipengaruhi oleh kondisi ekonomi nasional, kebijakan ketenagakerjaan, pertumbuhan angkatan kerja, serta peristiwa eksternal seperti krisis ekonomi dan pandemi. Oleh karena itu, pemahaman karakteristik data ini menjadi dasar penting sebelum dilakukan pemodelan prediksi menggunakan metode Long Short-Term Memory (LSTM).

4.2 Hasil Pelatihan Model LSTM

Setelah tahap praproses data selesai, data TPT dipersiapkan dalam bentuk time series untuk keperluan pelatihan model LSTM. Data kemudian dibagi menjadi data latih (training data) dan data uji (testing data) untuk mengevaluasi kinerja model. Hasil pembagian data menunjukkan bahwa jumlah data latih yang digunakan sebanyak 12 sampel, sedangkan data uji sebanyak 3 sampel, dengan masing-masing sampel memiliki dimensi waktu dan fitur yang telah disesuaikan dengan kebutuhan model LSTM.

Model LSTM kemudian dilatih selama 50 epoch menggunakan data latih. Proses pelatihan menghasilkan nilai loss dan validation loss yang cenderung menurun seiring bertambahnya epoch. Hal ini menunjukkan bahwa model mampu mempelajari pola data TPT secara bertahap dan stabil.




Gambar 4. 2 Ringkasan Hasil Pelatihan Model LSTM

Berdasarkan hasil tersebut, dapat disimpulkan bahwa model LSTM berhasil meminimalkan kesalahan prediksi selama proses pelatihan. Penurunan nilai validation loss menunjukkan bahwa model tidak hanya menghafal data latih, tetapi juga memiliki kemampuan generalisasi yang cukup baik terhadap data uji.

4.3 Visualisasi Hasil Prediksi

Visualisasi hasil prediksi dilakukan untuk memudahkan interpretasi dan evaluasi kinerja model LSTM. Grafik perbandingan antara data aktual dan hasil prediksi menunjukkan bahwa secara umum garis prediksi mengikuti pola data aktual dengan cukup baik.

Pada Gambar 4.3 ditampilkan grafik perbandingan antara nilai aktual Tingkat Pengangguran Terbuka (TPT) dan nilai hasil prediksi yang dihasilkan oleh model LSTM. Grafik tersebut memberikan gambaran visual mengenai kemampuan model dalam mengikuti pola data historis TPT.



Gambar 4. 3 Grafik Perbandingan Data Aktual dan Hasil Prediksi Tingkat Pengangguran Terbuka (TPT) Menggunakan Model LSTM

Melalui visualisasi, dapat diamati bahwa model LSTM mampu menangkap tren jangka panjang TPT di masing-masing provinsi. Perbedaan kecil antara garis prediksi dan garis aktual lebih sering terjadi pada periode dengan fluktuasi yang tajam, yang menandakan adanya perubahan pola yang sulit diprediksi hanya berdasarkan data historis. Visualisasi ini membantu dalam memahami kelebihan dan keterbatasan model LSTM secara intuitif. Dengan melihat grafik tersebut, dapat dinilai sejauh mana model mampu merepresentasikan pola data sebenarnya serta mengidentifikasi periode waktu yang memiliki tingkat kesalahan prediksi yang lebih tinggi.

4.4 Pembahasan Hasil Penelitian

Hasil penelitian menunjukkan bahwa metode Long Short-Term Memory (LSTM) memiliki kemampuan yang baik dalam memprediksi Tingkat Pengangguran Terbuka (TPT) di Indonesia berdasarkan provinsi. Model mampu memanfaatkan data historis untuk

menghasilkan prediksi yang mengikuti pola aktual. Keunggulan LSTM terletak pada kemampuannya dalam menangkap ketergantungan jangka panjang pada data time series. Hal ini sangat relevan untuk data TPT yang dipengaruhi oleh kondisi ekonomi sebelumnya. Dibandingkan metode konvensional, LSTM memberikan fleksibilitas yang lebih tinggi dalam memodelkan data nonlinier.

Namun demikian, hasil prediksi masih memiliki keterbatasan. Model LSTM hanya memanfaatkan data historis TPT tanpa mempertimbangkan variabel eksternal lainnya. Oleh karena itu, perubahan mendadak akibat faktor eksternal belum sepenuhnya dapat diprediksi secara akurat. Secara keseluruhan, hasil penelitian ini menunjukkan bahwa penggunaan LSTM merupakan pendekatan yang relevan dan potensial dalam memprediksi TPT di Indonesia. Dengan pengembangan lebih lanjut, model ini dapat menjadi alat bantu yang bermanfaat dalam perencanaan dan evaluasi kebijakan ketenagakerjaan.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan yang telah diuraikan pada bab sebelumnya, dapat disimpulkan bahwa Tingkat Pengangguran Terbuka (TPT) di Indonesia memiliki karakteristik yang berbeda-beda antar provinsi serta menunjukkan fluktuasi dari waktu ke waktu. Perbedaan tersebut dipengaruhi oleh kondisi ekonomi regional, struktur lapangan pekerjaan, serta dinamika pasar tenaga kerja di masing-masing wilayah.

Hasil analisis menunjukkan bahwa data TPT merupakan data runtut waktu (time series) yang memiliki ketergantungan terhadap nilai pada periode sebelumnya. Oleh karena itu, pendekatan pemodelan yang mampu menangkap hubungan jangka panjang sangat diperlukan untuk menghasilkan prediksi yang lebih akurat. Analisis deskriptif yang dilakukan pada tahap awal penelitian memberikan pemahaman yang kuat mengenai pola dan tren TPT sebagai dasar pemodelan.

Penerapan model Long Short-Term Memory (LSTM) dalam penelitian ini menunjukkan hasil yang cukup baik dalam memprediksi TPT berdasarkan provinsi. Model LSTM mampu mempelajari pola historis dan menghasilkan prediksi yang mengikuti tren data aktual. Meskipun terdapat selisih pada beberapa periode tertentu, secara umum model mampu menangkap arah pergerakan TPT dengan baik.

Hasil penelitian ini juga menunjukkan bahwa penggunaan LSTM relevan untuk data ketenagakerjaan yang bersifat nonlinier dan dinamis. Model mampu memberikan gambaran prediksi TPT yang dapat digunakan sebagai alat bantu analisis dalam perencanaan kebijakan ketenagakerjaan. Dengan demikian, tujuan penelitian untuk membangun model prediksi TPT berbasis LSTM telah tercapai.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat dipertimbangkan untuk pengembangan penelitian selanjutnya. Penelitian berikutnya disarankan untuk menambahkan variabel ekonomi lain seperti Produk Domestik Regional Bruto (PDRB), tingkat inflasi, tingkat pendidikan, dan jumlah penduduk usia kerja agar model dapat menangkap pengaruh faktor eksternal terhadap Tingkat Pengangguran Terbuka (TPT) secara lebih komprehensif.

Selain itu, penelitian selanjutnya dapat membandingkan kinerja model LSTM dengan metode prediksi lain, seperti ARIMA, GRU, atau metode machine learning lainnya. Perbandingan ini diharapkan dapat memberikan gambaran metode mana yang paling optimal untuk memprediksi TPT di Indonesia.

Saran lainnya adalah penggunaan data dengan frekuensi yang lebih tinggi, seperti data triwulanan atau bulanan, agar model dapat menangkap perubahan pola secara lebih detail. Pengembangan sistem dengan antarmuka interaktif juga dapat dipertimbangkan pada penelitian selanjutnya untuk memudahkan pengguna dalam memilih provinsi dan menampilkan hasil prediksi secara lebih dinamis. Dengan adanya pengembangan tersebut, diharapkan penelitian di bidang prediksi ketenagakerjaan dapat memberikan kontribusi yang lebih besar bagi pengambilan keputusan dan perumusan kebijakan berbasis data di Indonesia.

DAFTAR PUSTAKA

- [1] A. S. Darmawan and M. N. Mifrahi, “Jurnal Kebijakan Ekonomi dan Keuangan Analisis tingkat pengangguran terbuka di Indonesia periode sebelum dan saat pandemi covid-19,” vol. 1, no. 1, pp. 111–118, 2022.
- [2] A. Pangestu, A. I. Purnamasari, I. Ali, T. Informatika, and S. I. Cirebon, “Analisis Peramalan Tingkat Pengangguran Terbuka di Jawa Barat : Pendekatan Time Series menggunakan Metode ARIMA,” vol. 5, no. 1, pp. 18–25, 2026.
- [3] M. Yurtsever, “Unemployment rate forecasting : LSTM - GRU hybrid approach,” *J. Labour Mark. Res.*, 2023, doi: 10.1186/s12651-023-00345-8.
- [4] S. P. Stynes and M. Jilani, “Forecasting Unemployment Rates Using a Combined ARIMA and LSTM Approach National College of Ireland Kushagra Airen”.

Lampiran

Link OneDrive :

https://mikroskilacid-my.sharepoint.com/:f:/g/personal/221112623_students_mikroskil_ac_id/IgCouk-q6vAgR56jmVS24C4CAfimtXV-eY7GtSDJUyiNSWc?e=U5jAad